ระบบแนะนำหนังสือการ์ตูนแบบหลายพฤติกรรมสำหรับการเช่าอ่าน

MULTI – BEHAVIOR RECOMMENDATION WEB APPLICATION DEVELOPMENT FOR MANGA RENTAL SERVICES

MB-CGCN: Multi-Behavior Recommendation with Cascading Graph Convolution Networks

สมาชิกกลุ่มและอาจารย์ที่ปรึกษา



รศ. ดร.ปัญญาพล หอระตะ
อาจารย์ที่ปรึกษา



นางสาวการติมา คำภีร์
663380199-4



นายณัฐพัฒน์ แสนตรี
663380012-6

ปัญหาของระบบแนะนำแบบพฤติกรรมเดียว

Data Sparsity

- ผู้ใช้เช่าน้อยมาก
- ไม่สะท้อนความสนใจแท้จริง
- ทำนายความชอบได้ยาก

Cold-Start

- ผู้ใช้ใหม่ไม่มีประวัติ
- ความแม่นยำต่ำมาก
- ไม่สามารถแนะนำได้

ระบบที่ใช้แค่ **การเช่า** อย่างเดียวไม่พอ

วัตถุประสงค์และขอบเขตข้อจำกัด

วัตถุประสงค์

1. พัฒนาเว็บแอปพลิเคชันต้นแบบระบบแนะนำหนังสือการ์ตูนสำหรับการเช่าอ่าน
2. ออกแบบโมเดลแนะนำแบบหลายพฤติกรรม
3. ประเมินและเปรียบเทียบกับระบบแนะนำพฤติกรรมเดียวด้วย Recall@K และ NDCG@K

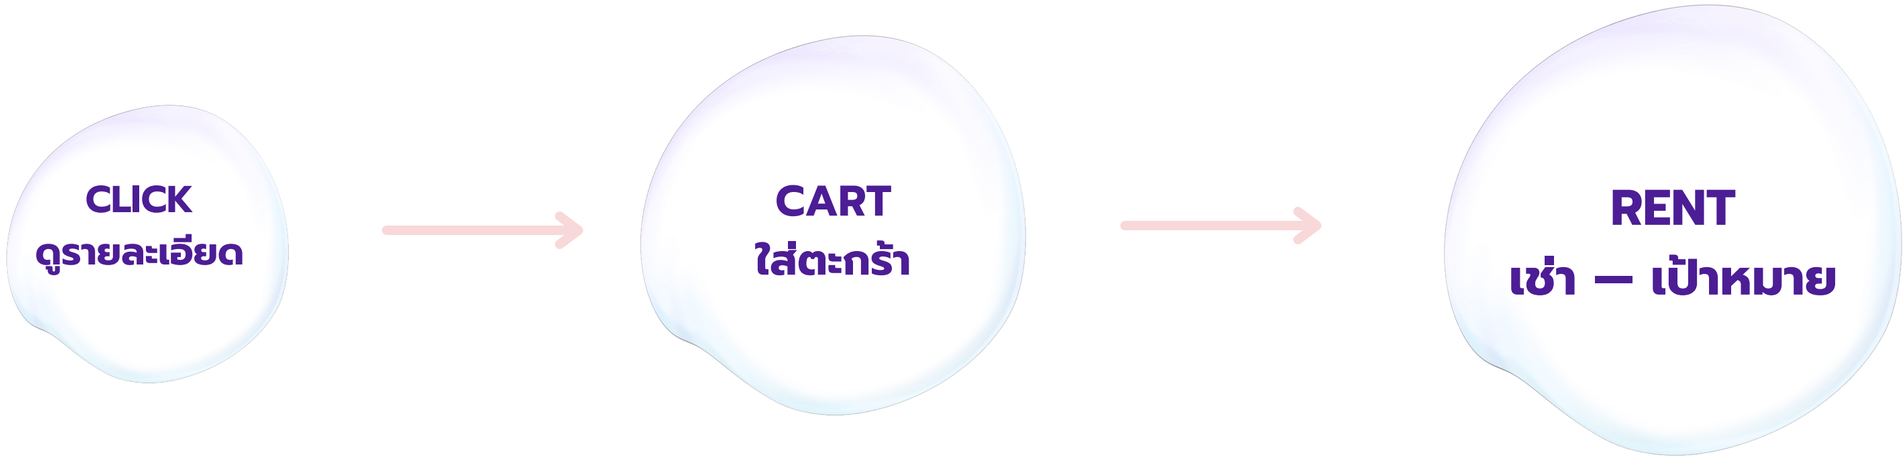
ข้อจำกัด

1. Cold-Start: ผู้ใช้ใหม่เลือกหนังสือที่ชอบ 4 เรื่อง ความแม่นยำช่วงแรกอาจยังไม่สูง
2. ไม่มีชำระเงินออนไลน์ จองผ่านเว็บ ชำระที่ร้าน
3. ข้อมูล v2 เป็นข้อมูลจำลอง หนังสือเพียง 100 เรื่อง ยังไม่ยืนยันกับผู้ใช้จริง
4. ทรัพยากรประมวลผลจำกัด

ขอบเขต

1. ข้อมูล: โมเดลที่หนึ่งใช้ MyAnimeList โมเดลที่สองใช้ข้อมูลจำลอง 1,000 ผู้ใช้ × 100 หนังสือ
2. ระบบ: เว็บแอปแบบ Prototype ส่วนผู้ใช้ ผู้ดูแลระบบ การแนะนำ และฝึกโมเดล
3. เทคนิค: PyTorch, PyTorch Geometric · Django REST · React (Vite) · PostgreSQL 15 Docker Compose · Railway

แนวคิด Multi-Behavior Recommendation



เก็บสัญญาณความสนใจระยะแรก • ถ่ายทอดความรู้ข้ามพฤติกรรม • เพิ่มความแม่นยำของการเช่า

โมเดลที่หนึ่ง (V1) ใช้ 2 พฤติกรรม คือ Cart → Rent เพราะชุดข้อมูล MyAnimeList ไม่มีพฤติกรรม Click

โมเดลที่สอง (V2) เพิ่ม Click เป็นห่วงโซ่ครบ 3 ขั้น Click → Cart → Rent โดยฝึกจากข้อมูลจำลอง เปลี่ยนใช้ข้อมูลจริงเมื่อเก็บเพียงพอแล้ว

ระบบแนะนำพื้นฐาน

วิธีการ	หลักการ	ข้อจำกัด
Collaborative Filtering	เรียนรู้จากผู้ใช้ที่คล้ายกัน	Data sparsity, Cold-Start
Content-based	จับคู่คุณลักษณะเนื้อหา	จำกัดความหลากหลาย
Hybrid	รวมหลายแนวทาง	ซับซ้อนและยังมักใช้พฤติกรรมเดียว

ต้องเรียนรู้จากหลายพฤติกรรม **ไม่ใช่เพียงการเช่า**

วิวัฒนาการโมเดล Deep Learning



data sparsity • cold - start • สัญญาณความสนใจสูญหาย

ต้องใช้โมเดลหลายพฤติกรรม

โมเดลหลายพฤติกรรมที่ศึกษา

NMTR	Neural Multi-Task Recommendation Gao et al., ICDE 2019	ถ่ายทอดแบบลำดับ - โครงสร้างตายตัว
MBGCN	Multi-Behavior Graph Convolutional Network Jin et al., SIGIR 2020	กราฟหลายพฤติกรรม - ต้นทุนสูง
CML	Contrastive Meta-Learning for Multi-Behavior Wei et al., WSDM 2022	Metric learning - จัดการลำดับจำกัด
KCL	Knowledge-Enhanced Contrastive Learning Xuan et al., WSDM 2023	Contrastive learning - ปรับจูนยาก
GHCF	Graph Heterogeneous Collaborative Filtering Chen et al., AAAI 2021	กราฟหลายชนิด - ซับซ้อน

ทำไมเลือก MB-CGCN

1 Cascading Architecture

ส่งต่อ embedding จาก CLICK, CART ไปยัง RENT ลดปัญหา data sparsity

2 Feature Transformation

เมทริกซ์แปลงคุณลักษณะ กรองสัญญาณรบกวนก่อนส่งต่อ

3 Target Supervision

ให้พฤติกรรมเป้าหมายกำกับการเรียนรู้ของพฤติกรรมต้นทาง

4 LightGCN Base

โครงสร้างเบา ตัด activation และ feature transform ที่ไม่จำเป็น

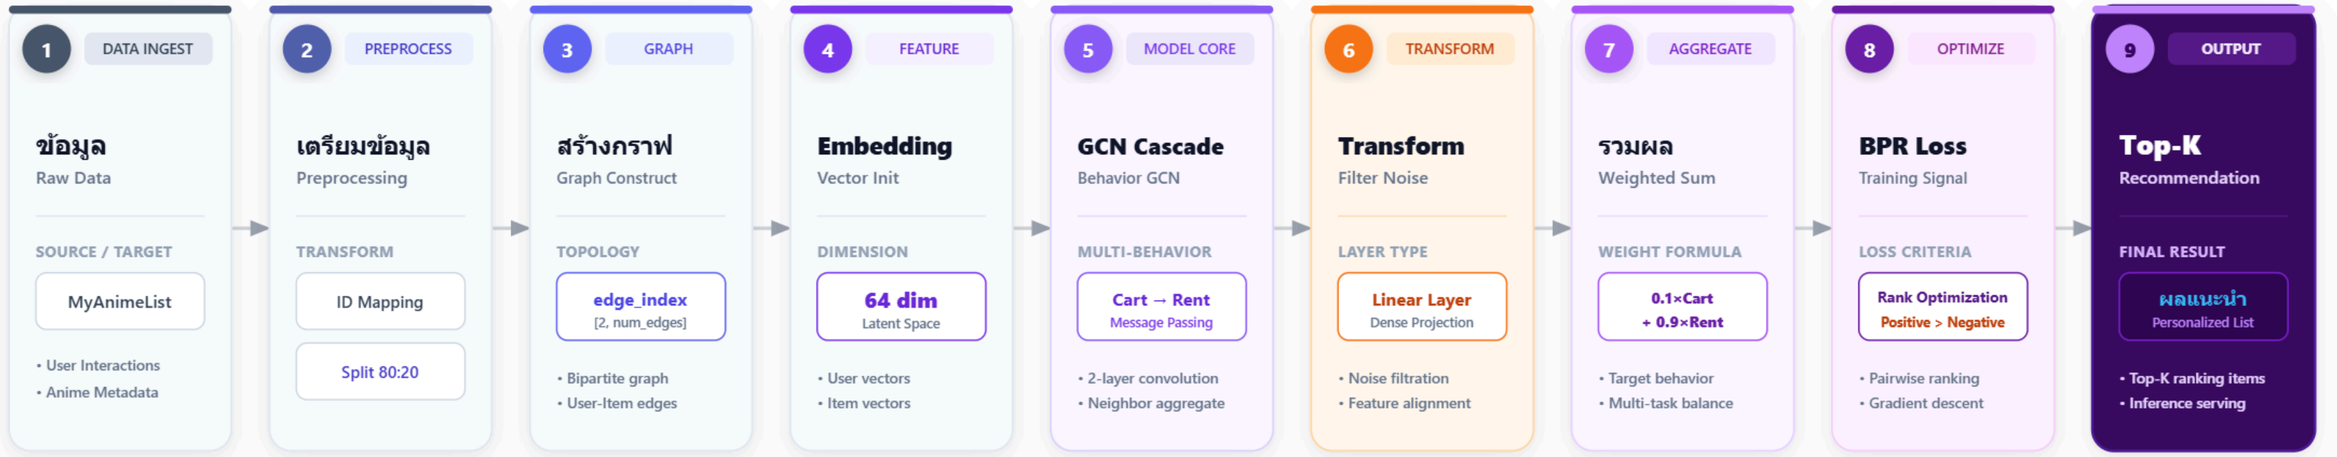
หลักฐานจากงานวิจัย

Dataset	Metric	CRGCN	MB-CGCN	Improvement
Tmall	Recall@10	0.0855	0.1233	+44.2%
Tmall	NDCG@10	0.0439	0.0677	+54.2%
Beibei	Recall@10	0.0459	0.0579	+23.2%
Beibei	NDCG@10	0.0324	0.0381	+17.6%

ที่มา: Cheng et al., "Multi-Behavior Recommendation with Cascading Graph Convolution Networks", WWW 2023

MB-CGCN ให้ผลสม่ำเสมอเหนือกว่าโมเดลกราฟหลายพฤติกรรมตัวเดิม

Pipeline การทำงานของโมเดลรุ่นแรก (V1)



COLOR-CODED LEGEND & PIPELINE PHASES

- **Data Ingestion & Prep** — Step 1-2 • Data cleaning & split
- **Graph & Embeddings** — Step 3-4 • Edge topology & vectors
- **Multi-Behavior GCN** — Step 5 • Graph convolution cascade
- **Transform & Aggregation** — Step 6-7 • Noise filtering & weights
- **Optimization & Output** — Step 8-9 • BPR Loss & Top-K results

Pipeline นี้ใช้ข้อมูลจริงจาก MyAnimeList: แปลงสถานะ Plan to Watch → Cart และ Watching/Completed → Rent แล้วเรียนรู้แบบลดหลั่นจาก Cart ไปยัง Rent

ชุดข้อมูล MyAnimeList

1,196,323
Users

27,702
Manga

Plan to Watch → CART
Watching, Completed → RENT

อนิเมะที่ดัดแปลงจากมังงะ ใช้เป็น proxy ของพฤติกรรมอ่านการ์ตูน

การเตรียมข้อมูล

1

ID Mapping

username → user_id,
anime_id → item_id

2

Edge Index สองทิศทาง

user → item และ
item → user

3

Train : Test = 80 : 20

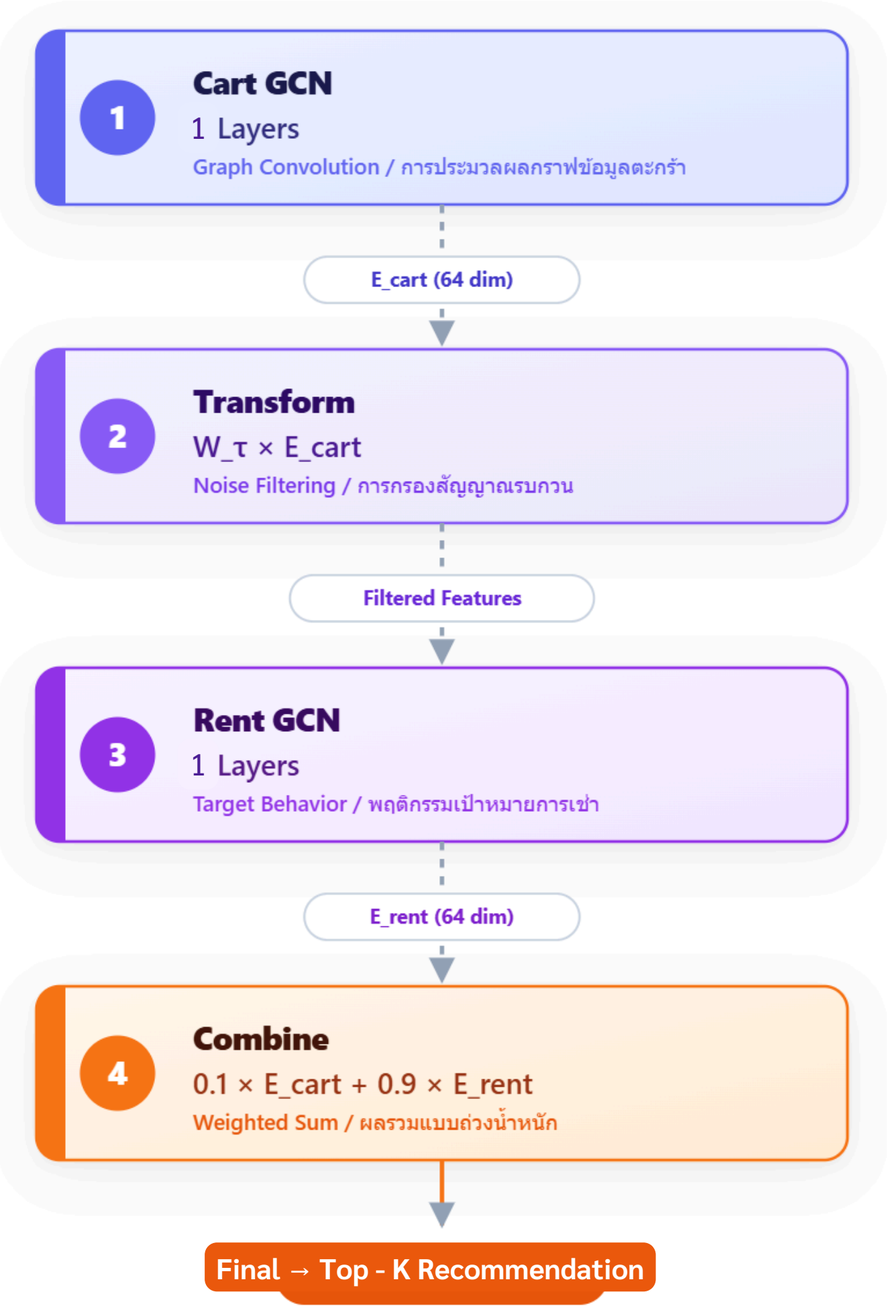
ตัวอย่าง มี 100, 000 edges
80,000 : 20,000 edges

4

Index Shifting

item_index + จำนวนผู้ใช้

สถาปัตยกรรม MB-CGCN รุ่นแรก (V1)



การฝึกโมเดล

BPR Loss

ทำให้คะแนนหนังสือที่เช่าจริง สูงกว่าหนังสือที่ไม่ได้เช่า

Bayesian Personalized Ranking Loss

ตัวอย่าง

s (user, rented) = 0.82 > s (user, negative) = 0.21

พารามิเตอร์	**โมเดลที่หนึ่ง (V1)**	**โมเดลที่สอง (V2)**
Loss	BPR, τ = 0.05	BPR
น้ำหนักพฤติกรรม	คงที่ 10:90	เรียนรู้ได้
L2	0.02	0.01 (weight_decay)
LR Scheduler	StepLR	ไม่ใช้
Batch	400,000 คู่/epoch	512 คู่/batch

ตัวชี้วัดการประเมิน

- **Recall@K** ใช้ประเมินประสิทธิภาพของระบบแนะนำ โดยวัดว่าจากรายการที่ผู้ใช้สนใจจริง ๆ ทั้งหมด ระบบสามารถแนะนำได้ถูกต้องกี่รายการ ภายใน K อันดับแรก

$$\text{Recall@K} = \frac{\text{หนังสือที่แนะนำใน K อันดับแรก} \cap \text{หนังสือที่ผู้ใช้เช่าจริง}}{\text{หนังสือที่ผู้ใช้เช่าจริงทั้งหมด}}$$

ตัวอย่าง ถ้าผู้ใช้เช่าจริง 5 เล่ม และโมเดลแนะนำ 20 เล่มแรกมีหนังสือที่ผู้ใช้เช่าจริงอยู่ 3 เล่ม

Recall@20 = 3/5 = 0.60 ค่ายิ่งสูงยิ่งดี หมายความว่าโมเดลค้นหาหนังสือที่ผู้ใช้สนใจได้มาก

ตัวชี้วัดการประเมิน

- **Normalized Discounted Cumulative Gain (NDCG@K)** ใช้ประเมินคุณภาพของลำดับการจัดอันดับในรายการแนะนำ โดยไม่ได้ดูแค่ว่าแนะนำถูกกี่รายการเหมือน Recall แต่ดูด้วยว่า รายการที่ถูกต้องและสำคัญนั้นอยู่ในตำแหน่งต้น ๆ หรือไม่

$$\text{NDCG@k} = \frac{\text{DCG@k}}{\text{IDCG@k}}$$

$$\text{DCG@k} = \sum_{i=1}^{k} \frac{2^{rel_i} - 1}{\log_2(i+1)}$$

$$\text{IDCG@k} = \sum_{i=1}^{\min(k,|R_q|)} \frac{1}{\log_2(i+1)}$$

นิยามตัวแปร

- rel_i = ค่าความเกี่ยวข้องของรายการในตำแหน่งที่ i (ผู้ใช้เช่าจริง = 1, ไม่เช่า = 0)
- IDCG@K = ค่า DCG สูงสุดที่เป็นไปได้เมื่อจัดเรียงตามความเกี่ยวข้องที่ถูกต้อง
- ค่า NDCG@K อยู่ในช่วง 0 ถึง 1 โดยค่า 1 หมายถึงการจัดอันดับที่สมบูรณ์แบบ

โมเดลฐานเพื่อเปรียบเทียบ

Matrix Factorization (MF)

- เรียนเวกเตอร์ user, item
- ใช้ dot product
- baseline แบบคลาสสิก

LightGCN

- Lightweight Graph Convolution
- ใช้พฤติกรรมเดียวคือ RENT

Popularity

- แนะนำหนังสือที่ถูกเช่ามากที่สุด
- ใช้พฤติกรรมเดียวคือ RENT
- baseline พื้นฐานที่สุด ไม่ต้องฝึก ใช้เฉพาะโมเดลที่สอง

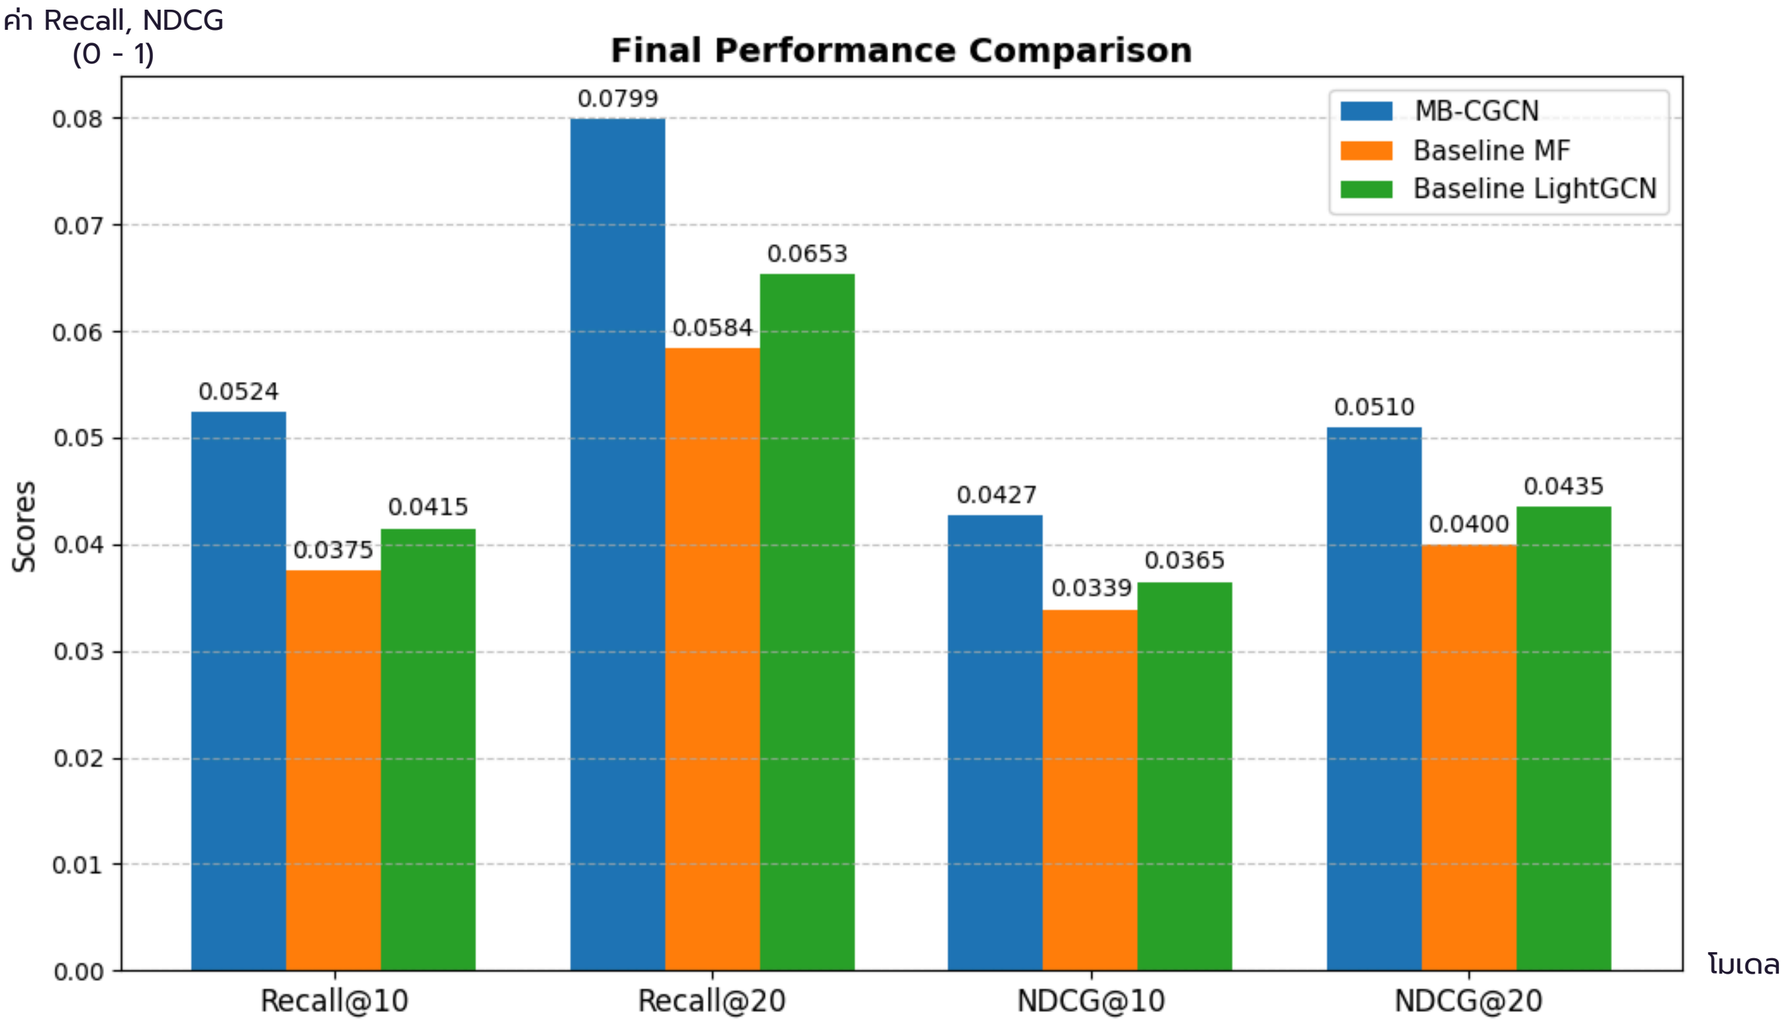
เงื่อนไขการฝึกเหมือนกัน เพื่อเปรียบเทียบอย่างเป็นธรรม

สรุปความต่างโมเดล V1 กับ V2

หัวข้อเปรียบเทียบ	MB-CGCN v1	MB-CGCN v2
ชุดข้อมูล	ข้อมูลจริงจาก MyAnimeList	ข้อมูลจำลอง 1,000 ผู้ใช้ × 100 หนังสือ
พฤติกรรม	2 รูปแบบ: Cart → Rent	3 รูปแบบ: Click → Cart → Rent
จำนวนชั้น GCN	1 ชั้นต่อพฤติกรรม	Click: 1 · Cart: 1 · Rent: 2
น้ำหนักพฤติกรรม	คงที่ 10:90 (Cart:Rent)	เรียนรู้ด้วย Softmax
การประเมินผล	สุ่มผู้ใช้ทดสอบ 1,000 คน	ใช้ผู้ใช้ทดสอบทั้งหมด
โมเดลเปรียบเทียบ	MF, LightGCN	MF, LightGCN, Popularity

ผลการทดลองของ V1 และ V2 ไม่สามารถเปรียบเทียบโดยตรงได้ เนื่องจากใช้ชุดข้อมูลและวิธีการประเมินผลที่แตกต่างกัน

ผลการทดลอง รุ่นแรก (V1)



Ablation Study: การทดสอบน้ำหนัก

	Fixed 10:90	**Learnable**
สัดส่วน Cart : Rent	0.10 : 0.90	0.49 : 0.51 (epoch 600)
Recall@20 (peak)	0.0799 (epoch 420)	0.0749 (epoch 600)
NDCG@20 (peak)	0.0516 (epoch 420)	0.0494 (epoch 600)
Recall@20 (epoch 600)	0.0708	0.0749
NDCG@20 (epoch 600)	0.0455	0.0494

ค่า peak ของ Fixed สูงกว่าเล็กน้อย แต่ที่ epoch 600 ทั้งสองใกล้เคียงกัน

- โมเดลที่หนึ่ง (V1) เลือก Fixed 10:90
- โมเดลที่สอง (V2) ใช้ Learnable เพราะมี 3 พฤติกรรมและไม่มีข้อมูลจริงมากำหนดสัดส่วน

MB-CGCN รุ่นที่สอง (V2) และข้อมูลจำลอง

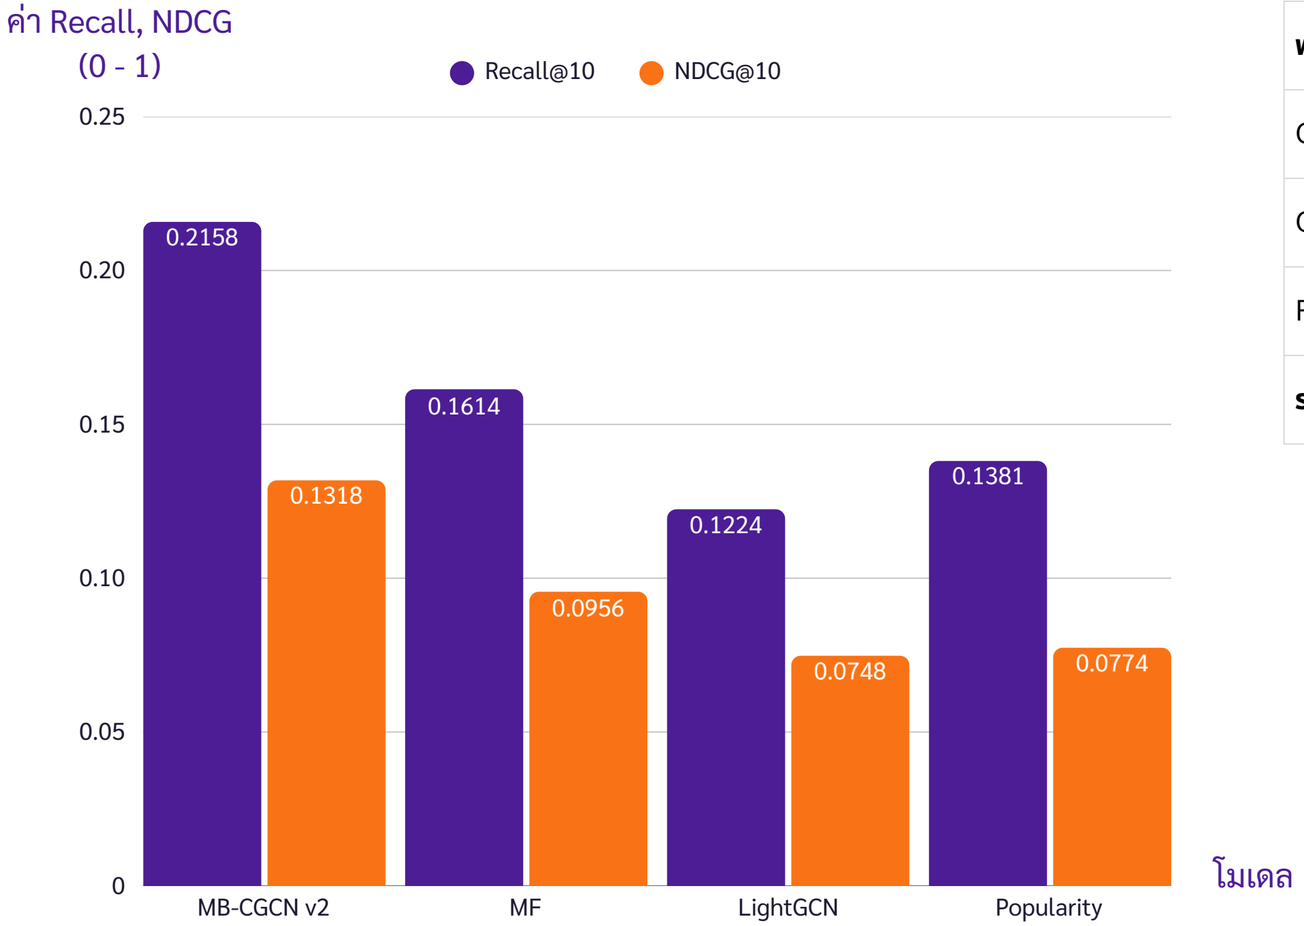
1
เพิ่ม CLICK
พฤติกรรมที่ 3

2
Learnable Weights
ให้น้ำหนักปรับได้

3
Rent 2 ชั้น
เพิ่มความลึกของกราฟ

ข้อมูลฝึกจำลอง
1,000 users × 100 manga

ผลการทดลอง รุ่นที่สอง (V2) ข้อมูลจำลอง



พฤติกรรม	Epoch 1	Epoch 600	เปลี่ยนแปลง
Click	0.0629 (6.29%)	0.0730 (7.30%)	+1.01 จุด
Cart	0.1710 (17.10%)	0.1736 (17.36%)	+0.26 จุด
Rent	0.7662 (76.62%)	0.7534 (75.34%)	−1.28 จุด
รวม	1	1	–

น้ำหนักเรียนรู้ได้ลงตัวที่

- Rent ≈ 75% เป็นสัญญาณหลัก
- Click เพิ่มเล็กน้อย 6.3% → 7.3%
- Cart คงที่ ≈ 17%

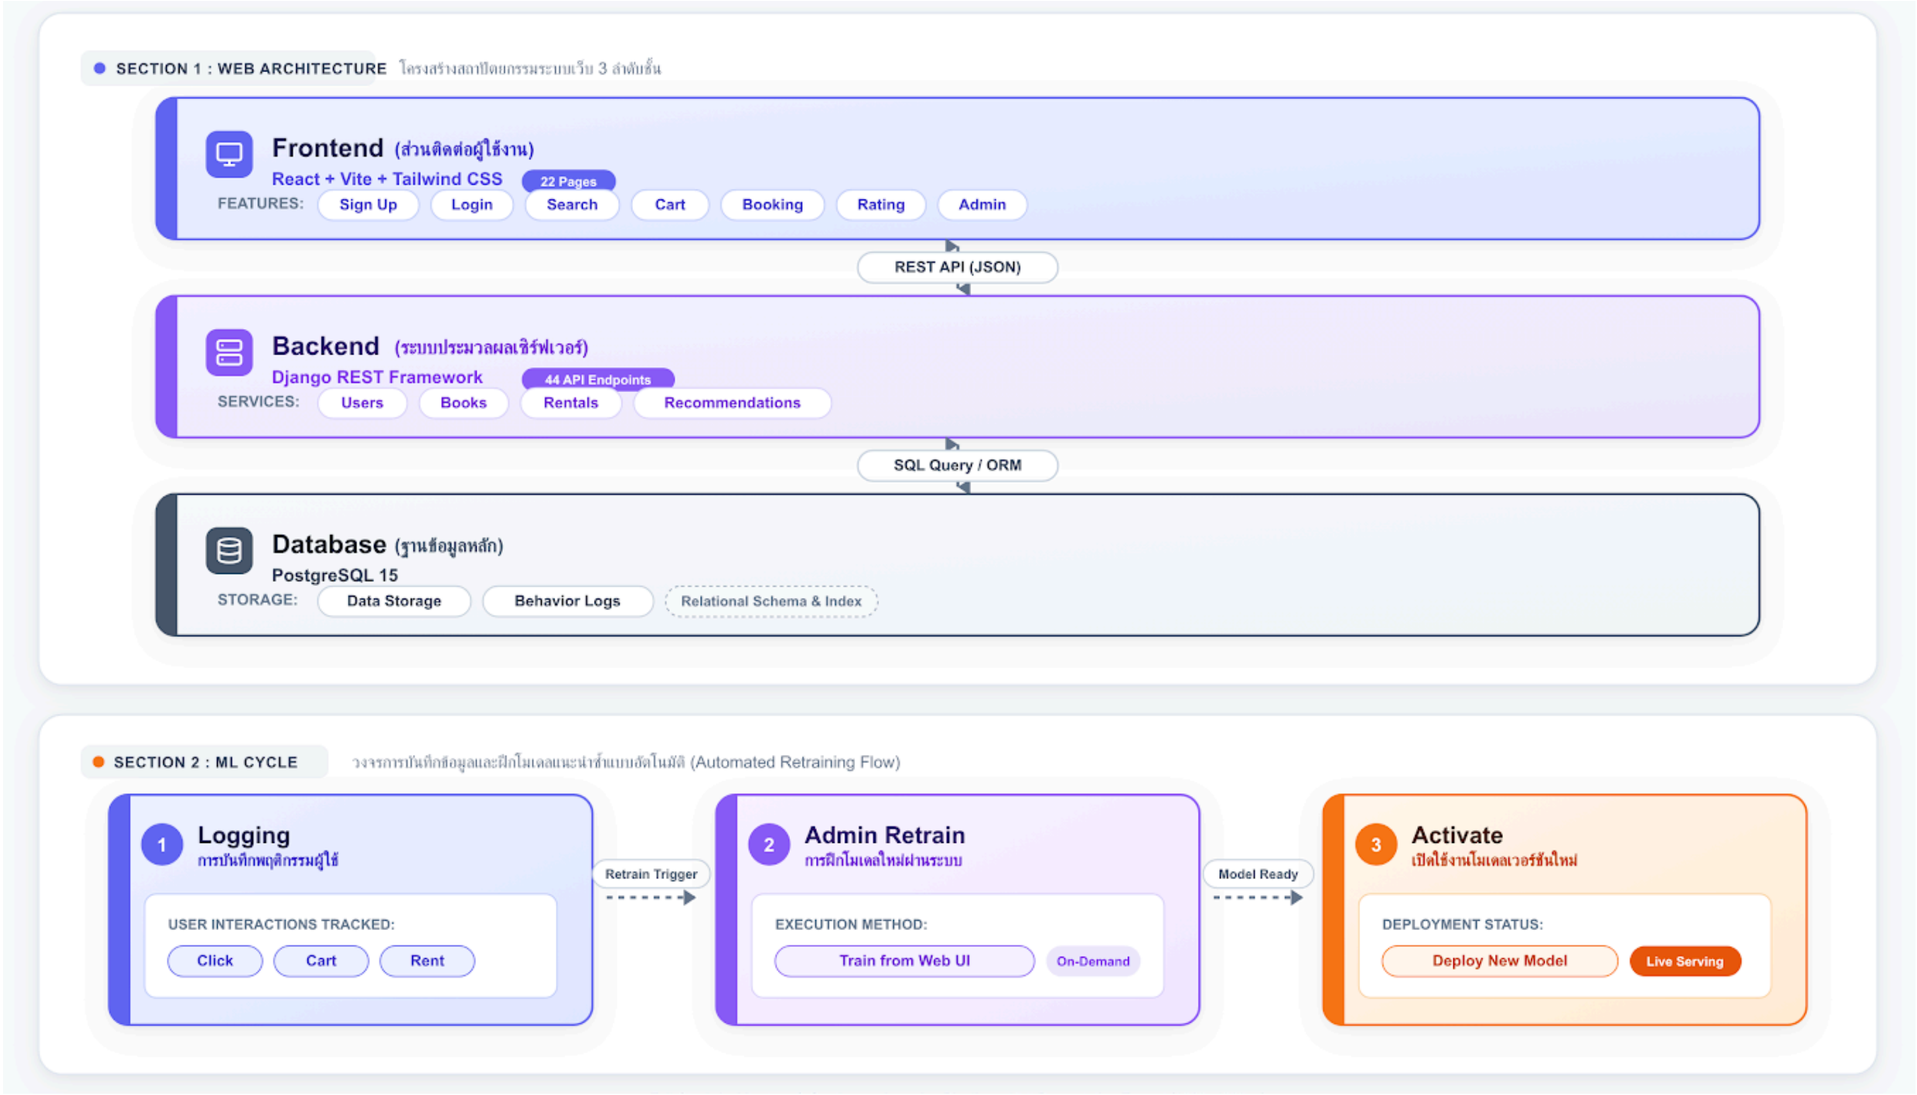
MB-CGCN (V2) ค่าสูงกว่าทุกโมเดลฐานบนข้อมูลจำลอง แสดงว่าโมเดลเรียนรู้ห่วงโซ่ Click → Cart → Rent ได้ แต่ยังต้องยืนยันด้วยพฤติกรรมผู้ใช้จริง

แก้ปัญหาผู้ใช้ใหม่ (Cold-Start)



- แก้ Cold-Start ทันที
- ไม่ต้องรอประวัติ

สถาปัตยกรรมระบบเว็บแอปพลิเคชัน



แนวทางพัฒนาต่อ

ด้านระบบแนะนำ

- เก็บข้อมูลผู้ใช้จริง แล้วฝึก v2 ใหม่ และเทียบกับ MF, LightGCN, Popularity บนข้อมูลชุดเดียวกัน
- แยกชุด Validation เพื่อเลือก Checkpoint ที่ดีที่สุด
- ทดลอง Fixed เทียบ Learnable Weights ของโมเดลที่สอง บนข้อมูลจริง
- แนะนำตามพฤติกรรมล่าสุดโดยไม่ต้องฝึกใหม่ทั้งกราฟ

ด้านระบบและฟังก์ชัน

- บันทึกพฤติกรรมให้ครบ เช่น source, position, “RENT” ตอนยืนยันรับหนังสือ
- เพิ่มปุ่ม "ไม่สนใจ" และแจ้งเตือนสถานะคำสั่งเช่าหรือใกล้ครบกำหนดคืน
- ย้ายงานเบื้องหลังและการฝึกโมเดลไป Worker แยก เช่น Celery หรือ Cron Job
- เพิ่ม Pagination, Rate Limiting, เก็บโทเค็นใน HttpOnly Cookie และชุดทดสอบอัตโนมัติ

สรุปผลการดำเนินโครงงาน

- เว็บแอปพลิเคชัน: ผ่านการทดสอบครบทุก Test Case แต่ยังไม่มีชุดทดสอบอัตโนมัติ
- โมเดล: MB-CGCN v1 (Cart → Rent, ข้อมูลจริง MyAnimeList) และ
  v2 (Click → Cart → Rent, ข้อมูลจำลอง)
  เชื่อมกับหน้า For You พร้อมแก้ Cold-Start
- โมเดลที่หนึ่ง: Recall@20 = 0.0799, NDCG@20 = 0.0510 สูงกว่า
  MF (0.0584, 0.0400) และ LightGCN (0.0653, 0.0435)
- โมเดลที่สอง: Recall@10 = 0.2158, NDCG@10 = 0.1318 สูงกว่า
  MF, LightGCN และ Popularity บนข้อมูลจำลอง
  ยังต้องยืนยัน v2 ด้วยพฤติกรรมผู้ใช้จริง

